

UNIVERSITÉ DE KINSHASA

Faculté des Sciences

Département d'Informatique

TRAVAIL PRATIQUE

IMPLÉMENTATION DE L'ALGORITHME DES NUÉES DYNAMIQUES

Implémentation à partir de zéro et application interactive

Étudiant : Lauclass Ekumu Nyanganze

Cours : Big Data / Sciences des Données

Année académique : 2025–2026

Kinshasa, 2026

Table des matières

Introduction	3
1 Présentation des nuées dynamiques	4
1.1 Définition	4
1.2 Principe général	4
1.3 Relation avec K-means	5
2 Conception de l'algorithme	6
2.1 Préparation des données	6
2.2 Initialisation	6
2.3 Affectation	6
2.4 Mise à jour	6
2.5 Critère	7
2.6 Condition d'arrêt	7
3 Types de représentations implémentés	8
3.1 Point ou centroïde	8
3.2 Points représentatifs	8
3.3 Axes factoriels	8
3.4 Distribution	9
3.5 Structure représentative	9
4 Implémentation informatique	10
4.1 Technologies utilisées	10
4.2 Organisation du projet	10
5 Application interactive	11
6 Expérimentation	12
6.1 Jeu de données Iris	12
6.2 Résultat avec un point représentatif	12
6.3 Résultat avec plusieurs points représentatifs	13

6.4	Résultat avec les axes factoriels	13
6.5	Résultat avec la structure représentative	13
6.6	Comparaison	14
Conclusion		15

Introduction

La classification automatique consiste à regrouper des individus en classes homogènes à partir de leurs caractéristiques. Dans une méthode de classification non supervisée, les classes ne sont pas connues à l'avance : elles sont construites à partir des ressemblances entre les individus.

La méthode des nuées dynamiques a été proposée par Edwin Diday en 1971 dans le domaine de la classification automatique et de la reconnaissance des formes [1]. Elle repose sur un processus itératif dans lequel les individus sont affectés à des classes puis les représentations de ces classes sont mises à jour.

L'objectif du présent travail est d'implémenter l'algorithme des nuées dynamiques à partir de zéro, sans utiliser directement une implémentation existante de K-means ou d'un autre algorithme de clustering.

Une application interactive a également été développée afin de permettre à l'utilisateur de charger un jeu de données, de sélectionner les variables, de choisir le nombre de classes et de sélectionner différents types de représentation des classes.

Le jeu de données Iris a été utilisé pour expérimenter l'algorithme et observer les différences obtenues selon la représentation choisie.

Chapitre 1

Présentation des nuées dynamiques

1.1 Définition

Les nuées dynamiques constituent une méthode de classification automatique non supervisée. Le principe général consiste à rechercher une partition des individus en plusieurs classes de manière à regrouper ensemble les individus qui se ressemblent.

La méthode repose sur un processus itératif. Une partition initiale est construite, les individus sont affectés aux classes selon une mesure de proximité, puis une représentation de chaque classe est calculée. Le processus est répété jusqu'à ce qu'une condition d'arrêt soit satisfaite.

Diday décrit cette approche comme une méthode permettant de rechercher une partition à partir des données en cherchant notamment à maximiser la ressemblance entre les individus d'une même partie et à réduire la ressemblance entre les individus de parties différentes [1].

1.2 Principe général

Le fonctionnement peut être résumé par les étapes suivantes :

1. charger et préparer les données ;
2. choisir le nombre de classes K ;
3. initialiser les représentations des classes ;
4. affecter chaque individu à la représentation la plus proche ;
5. mettre à jour les représentations des classes ;
6. calculer le critère de classification ;
7. vérifier la condition d'arrêt ;
8. recommencer si nécessaire.

1.3 Relation avec K-means

Les nuées dynamiques et K-means partagent un fonctionnement itératif : les individus sont affectés à des groupes puis les représentations des groupes sont mises à jour.

La différence essentielle considérée dans ce travail concerne la représentation d'une classe.

Dans K-means, une classe est représentée par un seul centroïde. Dans les nuées dynamiques, la représentation peut être plus riche. Elle peut notamment être constituée de plusieurs points représentatifs, d'axes ou d'une autre structure adaptée au problème.

Le cas où chaque classe est représentée par un seul point constitue donc un cas particulier proche du fonctionnement de K-means.

Chapitre 2

Conception de l'algorithme

2.1 Préparation des données

Les variables numériques sélectionnées sont extraites du jeu de données. Afin d'éviter qu'une variable ayant une échelle plus importante domine le calcul des distances, les données sont standardisées.

Pour une variable x , la standardisation utilisée est :

$$z = \frac{x - \mu}{\sigma}$$

où μ représente la moyenne de la variable et σ son écart-type.

2.2 Initialisation

Le nombre de classes K est choisi par l'utilisateur.

Des individus sont sélectionnés aléatoirement afin de servir de points initiaux pour les représentations des classes. Une graine aléatoire peut être définie afin de rendre les expérimentations reproductibles.

2.3 Affectation

Pour chaque individu, la distance avec chacune des représentations de classes est calculée.

L'individu est affecté à la classe dont la représentation présente la plus petite distance.

2.4 Mise à jour

Après l'affectation des individus, les classes sont reconstruites à partir des individus qui leur appartiennent.

La représentation dépend du type choisi par l'utilisateur.

2.5 Critère

Le programme calcule à chaque itération un critère correspondant à l'accumulation des distances entre les individus et les représentations des classes auxquelles ils sont affectés.

L'évolution de ce critère permet de suivre la stabilisation de l'algorithme.

2.6 Condition d'arrêt

L'algorithme s'arrête lorsqu'une des conditions suivantes est satisfaite :

- les affectations des individus ne changent plus ;
- la variation du critère devient inférieure à la tolérance fixée ;
- le nombre maximal d'itérations est atteint.

Chapitre 3

Types de représentations implémentés

L'application développée permet de sélectionner plusieurs représentations.

3.1 Point ou centroïde

Dans cette représentation, chaque classe est représentée par son centre moyen :

$$g = \frac{1}{n} \sum_{i=1}^n x_i$$

Il s'agit de la représentation la plus simple et du cas particulier qui se rapproche du fonctionnement de K-means.

3.2 Points représentatifs

Une classe peut également être représentée par plusieurs points.

Cette représentation permet de décrire une classe avec plusieurs éléments au lieu d'un seul centre.

Dans l'implémentation réalisée, plusieurs points sont sélectionnés comme représentants de la classe.

3.3 Axes factoriels

La représentation par axes factoriels utilise une décomposition en valeurs singulières (SVD) pour extraire des directions principales dans les données de chaque classe.

Les axes permettent de représenter la structure géométrique de la classe dans un espace de dimension réduite.

3.4 Distribution

Une représentation probabiliste a également été prévue dans le programme. Elle utilise une moyenne et une matrice de covariance.

La distance utilisée est basée sur une distance de type Mahalanobis :

$$d(x, \mu)^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

où μ représente la moyenne et Σ la matrice de covariance.

Cette représentation a été implémentée dans l'application, mais l'expérimentation réalisée avec le jeu de données Iris a rencontré une erreur d'exécution. Aucun résultat numérique n'est donc présenté pour cette représentation.

3.5 Structure représentative

Une structure représentative a également été implémentée.

Dans cette version, la classe est caractérisée par un centre et un rayon moyen représentant la dispersion des individus autour du centre.

Cette représentation constitue une structure adaptée à l'application développée.

Chapitre 4

Implémentation informatique

4.1 Technologies utilisées

L'application a été développée avec :

- Python ;
- NumPy pour les calculs numériques ;
- Pandas pour la manipulation des données ;
- Streamlit pour l'interface interactive ;
- Git et GitHub pour la gestion et le partage du code.

Aucune fonction de clustering de type K-means provenant de Scikit-learn n'a été utilisée pour réaliser le coeur de l'algorithme.

4.2 Organisation du projet

Le projet possède l'organisation suivante :

```
nuees_dynamiques/  
|  
|-- app.py  
|-- iris.csv  
|-- requirements.txt  
|-- README.md  
'-- rapport.tex
```

Le fichier `app.py` contient l'algorithme et l'application interactive.

Le fichier `iris.csv` contient le jeu de données utilisé pour les expérimentations.

Le fichier `requirements.txt` contient les dépendances Python.

Le fichier `README.md` présente le projet et explique son installation et son utilisation.

Chapitre 5

Application interactive

L'application permet à l'utilisateur de charger un fichier CSV ou Excel.

Lorsqu'aucun fichier n'est chargé, le jeu de données Iris présent localement dans le projet est utilisé.

L'interface permet notamment de choisir :

- les variables numériques utilisées ;
- le nombre de classes ;
- le type de représentation ;
- le nombre de points représentatifs ;
- le nombre d'axes factoriels ;
- le nombre maximal d'itérations ;
- la tolérance ;
- la graine aléatoire.

Après l'exécution, l'application affiche les classes obtenues, leur taille, l'évolution du critère, les représentations finales ainsi qu'un tableau de correspondance lorsque les classes réelles sont disponibles.

Chapitre 6

Expérimentation

6.1 Jeu de données Iris

Le jeu de données Iris est composé de 150 individus décrits par quatre variables numériques :

- longueur du sépale ;
- largeur du sépale ;
- longueur du pétale ;
- largeur du pétale.

Le jeu contient trois espèces : *Iris-setosa*, *Iris-versicolor* et *Iris-virginica*.

L'expérimentation a été réalisée avec $K = 3$ classes.

6.2 Résultat avec un point représentatif

La première expérimentation utilise la représentation par un point ou centroïde.

TABLE 6.1 – Correspondance obtenue avec la représentation par point

	Setosa	Versicolor	Virginica
Classe 1	0	39	14
Classe 2	50	0	0
Classe 3	0	11	36

La classe 2 contient les 50 individus appartenant à la classe Setosa. Les deux autres classes présentent un mélange entre Versicolor et Virginica.

6.3 Résultat avec plusieurs points représentatifs

TABLE 6.2 – Correspondance obtenue avec plusieurs points représentatifs

	Setosa	Versicolor	Virginica
Classe 1	0	42	16
Classe 2	49	8	1
Classe 3	1	0	33

La classe 2 regroupe principalement les Setosa, tandis que les classes 1 et 3 regroupent principalement les Versicolor et Virginica.

6.4 Résultat avec les axes factoriels

TABLE 6.3 – Correspondance obtenue avec les axes factoriels

	Setosa	Versicolor	Virginica
Classe 1	41	44	11
Classe 2	9	0	0
Classe 3	0	6	39

Cette représentation produit une organisation différente des individus. Les trois espèces ne sont pas séparées de manière identique à la représentation par centroïde.

6.5 Résultat avec la structure représentative

TABLE 6.4 – Correspondance obtenue avec la structure représentative

	Setosa	Versicolor	Virginica
Classe 1	0	14	19
Classe 2	50	0	0
Classe 3	0	36	31

La classe 2 contient ici les 50 Setosa. Les classes 1 et 3 contiennent principalement les deux autres espèces.

6.6 Comparaison

Les expérimentations montrent que le choix de la représentation influence directement la partition obtenue.

TABLE 6.5 – Synthèse des expérimentations

Représentation	Observation principale
Point / centroïde	Séparation complète des Setosa et mélange entre Versicolor et Virginica.
Points représentatifs	Les Setosa sont principalement regroupées dans une classe et les deux autres espèces sont mieux réparties entre deux classes.
Axes factoriels	La représentation basée sur les directions principales produit une partition différente.
Distribution	Représentation implémentée mais expérimentation interrompue par une erreur.
Structure représentative	Séparation complète des Setosa et regroupement des deux autres espèces dans les deux classes restantes.

Ces résultats illustrent l'intérêt de disposer de représentations de classes différentes. Une représentation par un seul point résume une classe par son centre, tandis que des représentations plus riches prennent en compte d'autres caractéristiques de la structure des données.

Conclusion

Ce travail a permis de réaliser une implémentation de l'algorithme des nuées dynamiques à partir de zéro et de développer une application interactive permettant son utilisation sur des données numériques.

Le fonctionnement général de l'algorithme a été mis en oeuvre à travers les étapes d'initialisation, d'affectation, de mise à jour des représentations et de vérification de la convergence.

Plusieurs types de représentations ont été intégrés : le point ou centroïde, les points représentatifs, les axes factoriels, la distribution et une structure représentative.

L'expérimentation sur le jeu de données Iris montre que la représentation choisie influence la partition finale. Cette observation constitue un élément essentiel de la méthode des nuées dynamiques : la classe n'est pas nécessairement limitée à un unique centroïde.

Une amélioration future pourrait consister à renforcer les méthodes de construction des représentations, notamment la représentation probabiliste, ainsi qu'à ajouter davantage de critères d'évaluation et de jeux de données.

Bibliographie

- [1] E. Diday, *Une nouvelle méthode en classification automatique et reconnaissance des formes : la méthode des nuées dynamiques*, Revue de Statistique Appliquée, vol. 19, no. 2, pp. 19–33, 1971.
- [2] R. A. Fisher, *The use of multiple measurements in taxonomic problems*, Annals of Eugenics, vol. 7, no. 2, pp. 179–188, 1936.